

LLM и SLM на стенде инцидента Hugging Face

Источники: provider_compare_openai_hf.json · shared_graph_llm_slm.json · 13 сентября 2026 · M1 n=12 · M4 n=6 · граф пересобирается для каждого бэкэнда RAG

Граф АН (стенд 1): ручная фикстура

SLM qwen3:8b

LLM deepseek-chat / GigaChat-2-Pro

EXPLAINSORE АН
0,25

M5 ПРОТИВ GIGACHAT
−0,080


M5 ПРОТИВ DEEPSEEK
+0,104

ГАЛЛЮЦИНАЦИИ АН
0,17

Что измеряют первые столбцы. M1 — извлечение ролей из одних и тех же коротких фраз, а не ответы по общему графу. Оценки АН на M4 совпадают, потому что декодер графа не вызывает чат-модель. Столбцы RAG — чат-модель пересказывает найденные фрагменты.


M1 · F1 ролей — АН-gated против без гейта

Нормированный взвешенный F1 (SUBJECT/OBJECT вес 2). Порог Middle = 0,6. Ось: модель · F1 (0–1).



M4 · доля галлюцинаций — тот же граф АН против каждого писателя RAG

Доля из 6 вопросов, помеченных как галлюцинация. Ось: бэкэнд RAG · доля (0–1).



M4 · дельта объяснимости

ExplainScore_АН – ExplainScore_RAG. У RAG оценка объяснимости равна 0 (нет трассы UID). После пересборки АН остаётся 0,25 для каждого бэкэнда.



Числа M1

МОДЕЛЬ	АН-GATED	БЕЗ ГЕЙТА	АН – БЕЗ ГЕЙТА	ПРОТИВ 0,6
qwen3:8b	0,381	0,433	−0,052	не проходит
GigaChat-2-Pro	0,654	0,681	−0,027	проходит
deepseek-chat	0,605	0,781	−0,176	проходит gated

Разбор пунктов M4 (декодер АН)

ВОПРОС	АН	EXTRACTIVE RAG
Что такое IM1?	попадание + трасса	попадание (чанк)
Какая оценка дала инцидент HF?	промах	промах
Где была доска сообщений?	Artifactory + трасса	попадание
Какой 0-day формата файла?	промах (дата)	попадание
Каскад тревог → Astra?	промах	промах
Секретный код запуска IM1?	нет отказа	нет отказа

Как читать стенд 1. SLM против LLM на M1 — разрыв парсера. Пересобранная фикстура АН не меняется вместе с писателем RAG.
Стенд 2: одна модель собирает граф, затем обе отвечают только по этому графу.


Общий граф — один строитель, отвечают обе модели

Источник: shared_graph_llm_slm.json · та же статья, 26 батчей · ingest DeepSeek против qwen3:8b · закрытая генерация, без корпуса RAG

ФАКТОВ В ГРАФЕ LLM 438	ФАКТОВ В ГРАФЕ SLM 301	ПОКРЫТИЕ LLM / SLM 0,99 / 0,92
---------------------------	---------------------------	-----------------------------------


Кто собрал память

Ось: метрика · число.




Один граф, отвечают обе модели — верность

Закрытая генерация по одинаковому контексту графа. n=6. Ось: кто собрал граф · доля верных (0–1).



Один граф — отказ против галлюцинации

Обе чат-модели на каждом пункте сказали «неизвестно» (отказ = 1). Галлюцинации генератора = 0. Декодер отвечает без отказа.



КТО СОБРАЛ ГРАФ	ФАКТОВ	ВЕРНОСТЬ ДЕКОДЕРА	LLM ПО ГРАФУ	SLM ПО ГРАФУ
deepseek-chat	438	0,50	0,17 (все отказались)	0,17 (все отказались)
qwen3:8b	301	0,33	0,17 (все отказались)	0,17 (все отказались)

Наконец равная позиция. Когда обе модели видят один и тот же фрагмент графа и не могут опереться на внешние знания, DeepSeek и 8b дают одинаковые ответы. Остаётся разрыв, кто собрал граф (438 против 301 фактов) и декодер, который говорит без чат-модели.