

ЗАЩИТА ПРОЕКТА

Как текст становится графом, а граф — контекстом модели

Ассоциативно-гетерархическая память: построение, воспламенение, точки входа, закрытый контекст и метрики M1–M5.

АН-memory · сентябрь 2026 · клавиши ← →, N — заметки

Сначала контур, потом измерения

Контур

- 1. Как из текста строится граф.
- 2. Как выбираются точки входа.
- 3. Как работает воспламенение.
- 4. Что в итоге попадает в контекст модели.

Проверки

- 5. Суть тестов M1–M5.
- 6. График каждой метрики с полной легендой.
- 7. Итоговый F1 и вывод.

Текст сначала разбирается, в граф ещё не пишется

- 1. **Perception.** Модель (DeerSeek, GigaChat или Ollama) возвращает JSON: предикат, роли актантов, цитату raw_span, уверенность. Это кандидаты, не факты памяти.
- 2. **Роли протокола.** Допускаются только SUBJECT, OBJECT, LOCATION, TIME, CAUSE, TOOL, MATERIAL, PURPOSE, HOW-TO, WITH. Прочие поля отбрасываются схемой, а не «догадкой про зайца».
- 3. **Семена.** Даже без полного факта слой отмечает, о каких сущностях речь: seed_tokens. Они понадобятся как точки входа при вопросе.

Фраза: «Заяц обитает на лугу» Кандидат: LIVE_IN · SUBJECT=заяц · LOCATION=луг · raw_span=«Заяц обитает на лугу»

Гейт пускает только то, что есть в исходном тексте

Проходит

- Роль заземлена в фразе (лемма / вхождение).
- Уверенность не ниже порога (0,5).
- UID роли не слишком широкий («всё», «они»).

Не проходит

- Сущность, которой в тексте нет: модель додумала.
- Роль вне протокола.
- Кандидат без двух актантов: фактор не из чего собрать.

Гейт — сито, не вторая модель. Он не добавляет знаний и не уравнивает 8b с DeepSeek.

Transform записывает событие и n-арный фактор

1. **Символы.** Для каждой роли: абстрактный символ в S и карточка второго порядка (ярлык «заяц», «луг»).
2. **Отношение.** Сырое имя нормализуется в каноническую метку реестра. Неизвестный предикат регистрируется, код под него не пишется.
3. **Event + Factor.** Появляется событие с ролями-ссылками и семантический фактор N. Это гиперребро, не чанк текста.
4. **Связки.** Между актантами одного факта ставится ASSOC — микротема для последующего воспламенения.

Мутации идут только через Store / DSL. Perception в граф не пишет. Дубликаты того же предиката и тех же ролей не плодятся.

После записи в памяти лежит структура, а не абзац

АН = {S, C, P, H, L} + факторы N		
S	символы и словоформы	«заяц», «луг»
C/P/H	общее / частное / эпизоды	карточка на одной полке
L	бинарные связи	IS-A, FOLLOW, ASSOC
N	n-арный факт	LIVE_IN(SUBJECT=заяц, LOCATION=луг)
UID	стабильный адрес узла	по нему потом строится трасса

Корпус RAG при этом существует отдельно: те же документы режутся на чанки для контроля. У чанка нет UID и нет ролей.

Вопрос не записывается. Он ищет якоря в уже построенном графе

1. **Сброс.** Сообщения belief propagation и рабочая память прошлого вопроса гасятся. Сам граф не трогается.
2. **Сначала упоминания.** В формулировке ищутся самые длинные точные имена сущностей из S. «Заяц» бьёт в UID зайца, а не в случайный токен.
3. **Затем семена Perception.** Если точного упоминания нет, берутся seed_tokens и словоформы. Не больше 16 якорей.
4. **План запроса.** Среди соседних фактов якоря выбирается одна связь и один слот ответа (кто / что / где). Победившие факторы получают маску 1, остальные — 0.

Писать вопрос как факт нельзя: иначе память засоряется своей же формулировкой.

Якоря получают evidence, такт несёт активацию по факторам

1. **Семена.** Каждому якорю кладётся evidence $\delta = 0,8$. Это старт фокуса, не новый факт.
2. **Такты ВР.** Сообщения переменная $\rightarrow$ фактор и фактор $\rightarrow$ переменная. Потенциал фактора смотрит на роли и маску плана.
3. **Активация.** Скаляр x узла обновляется из вклада факторов, затухает с $\lambda = 0,15$. Полураспад $\approx 4,6$ такта.
4. **Рабочая память.** $WM = \{ \text{узлы с } x > t \}$, $t = 0,55$. Ниже порога — шум, в ответ не идёт.
5. **Трасса.** UID, которые вспыхнули по тактам, плюс факторы с вкладом выше ε . Это доказательство, не похожесть чанка.

Структура Store здесь не меняется. Ignition не вызывает языковую модель.

В промпт идёт сжатый список фактов, а не UID и не весь граф

Как отбирается

Ранжировщик считает релевантность фактора к вопросу: лексика формулировки, активация узлов, маска плана, поддержка соседей. В промпт — до 12 фактов с ненулевым счётом. Сырые UID в текст не попадают, только человекочитаемые ярлыки и цитаты.

Закрытый мир

Системный блок говорит: опирайся только на этот список; не добавляй места, даты, числа и связи, которых нет; если факта нет — ответь ровно «неизвестно». Общие знания запрещены. Если компактный список пуст, запасной путь — строка декодера «Активировано: ...».

От фразы до того, что видит модель

Запись: «Заяц обитает на лугу» → LIVE_IN(SUBJECT=заяц, LOCATION=луг) в графе Вопрос: «Где обитает заяц?» → якорь: заяц → воспламенение: заяц, луг, фактор LIVE_IN → декодер читает слот LOCATION → «луг» Контекст модели: [Контекст из АГ-памяти — единственный источник фактов] • обитает: субъект заяц, место луг Пользовательская реплика модели: «Где обитает заяц?» Ответ модели должен перефразировать только этот список.

Пять метрик проверяют разные звенья одной цепи

МЕТРИКА	ЧТО ИМЕННО ПРОВЕРЯЕТ	ГДЕ В КОНТУРЕ
M1	Верно ли Perception ставит роли SUBJECT / OBJECT / LOCATION	разбор текста, до записи
M2	Доходит ли активация до ответа и полна ли трасса UID	воспламенение
M3	Удаляет ли GC сирот, не трогая живые узлы	память после тактов
M4	Есть ли объяснимость и меньше ли галлюцинаций, чем у RAG	контекст + ответ vs чанки
M5	Даёт ли типизация ролей фору маленькой модели	M1 на SLM против LLM

F1 — это M1. Остальные метрики не F1: ExplainScore, доля собранных сирот, две дельты относительно RAG.

Одни и те же короткие фразы, две разборки ролей


Протокол

12 шаблонных предложений стенда инцидента Hugging Face. Эталон — тройки SUBJECT / OBJECT / LOCATION. Вес субъекта и объекта = 2, локации = 1. Считается нормированный взвешенный F1. Порог Middle из постановки: $\geq 0,6$.

Два режима

АН-gated — после гейта: в счёт идут только роли, заземлённые в тексте. **Без гейта** — сырой JSON модели. Здесь нет общего графа и нет ответа на вопрос: измеряется только парсер на границе.

Класс модели важнее гейта



■ **Синие столбцы — AN-gated F1.** Модель предложила роли, гейт оставил только те, что встречаются в исходной фразе. Это тот разбор, который реально идёт в Transform.

■ **Серые столбцы — F1 без гейта.** Та же модель, тот же текст, без сита. На коротких шаблонах серый столбец чуть выше: гейт отбрасывает лишнее, эталону это не помогает.

Вертикаль 0...1 — нормированный взвешенный F1. Линия 0,6 на шкале — порог Middle. n = 12.

Верный ответ считается только вместе с полной трассой

Офлайн-стенд: 20 вопросов с эталонной цепочкой UID длины 1...6. Модель чата не вызывается. Срабатывает только воспламенение и декодер.

$$\text{ExplainScore} = (1/N) \sum 1_{\text{верный}} \cdot (\text{глубина} / 6) \cdot 1_{\text{трасса_полная}}$$

Если ответ угадан, но в трассе нет эталонной подпоследовательности UID — вклад нулевой. Это проверка точек входа и тактов, не беглости текста.

На глубине 1–4 трасса доходит, на 5–6 — нет



Синие — доля вопросов этой глубины, где ответ верен и трасса UID полная. На d = 1...4 это все кейсы (4, 3, 3 и 3 вопроса).
Серые — кейсы, где активация не дошла до эталонного UID. Все 3 вопроса глубины 5 и все 4 вопроса глубины 6.
Итоговый ExplainScore = 0,26: 13 из 20 с полной трассой, вклад взвешен глубиной. Провал d = 5–6 — затухание и порог WM, не отсутствие механизма.

Сборка мусора снимает сирот и не трогает живое



■ Серый столбец — 200 сирот до GC. Узлы без связи, TTL = 50 тактов.
■ Зелёный столбец — сироты после GC. Ноль. Живые LIVE / M_LIVE и их связь сохранены, ложных удалений нет.
Метрика постановки: доля собранных сирот = $1 - N_{\text{после}} / N_{\text{до}}$ = **1,00**. Это санитарный инвариант памяти, не качество парсера.

Тот же корпус: граф с трассой против чанков без UID

АГ-память

Вопрос → якоря → воспламенение → ответ из WM. ExplainScore ненулевой, только если ответ верен и трасса содержит эталонные UID.

Vanilla RAG

Те же документы режутся на фрагменты. Поиск TF-IDF или FAISS, затем извлечение или пересказ моделью. Поля трассы UID нет, поэтому ExplainScore RAG по постановке всегда 0.

Δ объяснимости = $E_{\text{АН}} - E_{\text{RAG}}$. Δ галлюцинаций = $H_{\text{RAG}} - H_{\text{АН}}$. Два независимых золота: заяц (n = 6) и инцидент Hugging Face (n = 6, граф пересобирается на каждый бэкенд).

На монографии гипотеза закрыта целиком




Синие — АГ-память. ExplainScore 0,67: ответы с трассой. Галлюцинации 0: на лунном короле зайцев система сказала «неизвестно».

Красные — Vanilla RAG с DeepSeek. ExplainScore 0: нет UID. Галлюцинации 0,50: генератор дописывает массу и энциклопедию сверх фрагмента.

Ось 0...1. Левая пара — объяснимость (больше лучше). Правая — доля галлюцинаций (меньше лучше).

После пересборки графа Δ объяснимости = 0,25 против любого RAG




Зелёные — Δ объяснимости. 0,25 на всех четырёх бэкендах, потому что граф и агент собираются заново: след активации прошлого RAG больше не портит АН.

Красные — доля галлюцинаций RAG. Extractive цитирует чанк (0,33). Чат-модели на закрытом промпте всё равно дописывают (1,0). Галлюцинации АН на этом стенде 0,17 — ловушка с секретным кодом, где отказ не случился.

Ось 0...1. n = 6 вопросов. ExplainScore RAG = 0 по контракту метрики.

Типизация ролей не компенсирует слабость 8b



Формула: $RobustnessGain = (F1_{AH_SLM} / F1_{без_гейта_SLM}) - (F1_{AH_LLM} / F1_{без_гейта_LLM})$. Ожидание постановки: плюс, если гейт сильнее помогает маленькой модели.

■ **Против GigaChat: −0,080.** Отвергаем гипотезу: 8b выигрывает от гейта меньше, чем коммерческая модель.

■ **Против DeepSeek: +0,104.** Плюс из-за просадки gated F1 у DeepSeek (0,605 против 0,781 без гейта), а не потому что 8b вырос. Честный reject по GigaChat — валидный исход.

Нормированный взвешенный F1 ролей после контура Perception

0,381

qwen3:8b · AN-gated · ниже порога 0,6

0,654

GigaChat-2-Pro · AN-gated · Middle пройден

0,605

deepseek-chat · AN-gated · Middle пройден

МОДЕЛЬ	F1 С ГЕЙТОМ	F1 БЕЗ ГЕЙТА	ВЕРДИКТ
qwen3:8b		0,381	0,433 не проходит Middle
GigaChat-2-Pro		0,654	0,681 проходит
deepseek-chat		0,605	0,781 проходит gated

Контроль на 16 репликах DeepSeek в пояснительной записке: F1 = 0,705 (LOCATION 0,86 · OBJECT 0,67 · SUBJECT 0,67). F1 измеряет парсер, не воспламенение.

Что следует из контура и из чисел

Контур работает как заявлено

- Текст становится гиперрёбрами с ролями, не мешком чанков.
- Точки входа — якоря в вопросе, не запись вопроса в память.
- Воспламенение зажигает WM; в модель идёт сжатый закрытый список фактов.
- M3 = 1,0. M4: Δ объяснимости > 0, потому что у RAG нет трассы UID.

Где предел

- Итоговый F1 следует за классом парсера: 8b не дотягивает до 0,6, коммерческие модели дотягивают.
- Гейт не лечит слабый JSON. M5 отвергнут.
- Длинные цепи d = 5–6 гаснут. На ловушках отказ не всегда срабатывает.
- Когда обе модели видят один граф, ответы уравниваются: разрыв был во входе, не в «уме».

Память хранит доказательство. Модель только разбирает текст на входе и пересказывает выданный контекст.

КОНЕЦ

Вопросы

Граф ← текст. Контекст ← воспламенённые факты. F1 ← качество парсера на границе.

[docs/zashchita.html](#) · [docs/zashchita.pdf](#) · N — заметки докладчика